

Universität zu Köln  
Sprachliche Informationsverarbeitung  
Hauptseminar: Angewandte linguistische Datenverarbeitung  
Prof. Dr. Jürgen Rolshoven  
Hausarbeit

# **Semantische Spezifität im Word Space Model**

Von C. Friedrich

(Vorgelegt am 30. August 2016)

Ladida, ladidu

# Inhaltsverzeichnis

<b>1</b>	<b>Einleitung</b>	<b>3</b>
<b>2</b>	<b>Ein Maß für die semantische Spezifität</b>	<b>3</b>
2.1	Textgrundlage . . . . .	3
2.2	Score #1: Document Frequency . . . . .	3
2.3	Das Word Space Model . . . . .	4
2.4	Satzkookkurrenzen vs. Fensterkookkurrenzen . . . . .	4
2.5	Score #2: Anzahl der Kookkurrenzen . . . . .	5
2.6	Maße für die Kookkurrenzen . . . . .	6
2.6.1	Binäre Kookkurrenz . . . . .	6
2.6.2	Frequenz der Kookkurrenz . . . . .	6
2.6.3	Dice-Koeffizient . . . . .	7
2.6.4	Chi-Square . . . . .	7
2.7	Distanzmaße im Vektorraum (fast unnötig) . . . . .	7
2.8	Score #3: Semantische Nähe des Kontextes . . . . .	7
2.9	Getestete Maße . . . . .	8
2.10	Wordpaare . . . . .	8
2.11	Resultate . . . . .	8
<b>3</b>	<b>Ein Modell für Anglizismen</b>	<b>8</b>
3.1	Textgrundlage . . . . .	8
3.2	Verwendete Technologien . . . . .	8
3.3	Resultate . . . . .	8
<b>4</b>	<b>Konklusion</b>	<b>8</b>
<b>5</b>	<b>Ausblick</b>	<b>8</b>

# 1 Einleitung

## Semantische Spezifität

Jones (1972, 11) Beschreibt die Spezifität eines Begriffes so:

Specificity ... is a semantic property of index terms: a term is more or less specific as its meaning is more or less detailed and precise.

## Semantische Spezifität und Anglizismen

# 2 Ein Maß für die semantische Spezifität

## 2.1 Textgrundlage

Welche Korpora werden verwendet?

Wie sieht das Präprozessieren aus?

Keine Bigramme.

Frequency Threshold.

## 2.2 Score #1: Document Frequency

Bereits Jones (1972) schlug ein statistisches Maß für die semantische Spezifität eines Wortes vor. Es ist die simple Frequenz, mit der ein Wort im Korpus auftaucht, das ein Indiz für die Spezifität darstellen soll. Caraballo und Charniak (1999) konnten die *document frequency* als Eigenschaft von Worten dazu nutzen, für beliebige Wortpaare festzustellen, welches Wort spezifischer oder genereller ist. Überprüft wurde das mit Beispielwortpaaren, die in einer Hyperonym- bzw. Hyponymrelation zueinander stehen: Das Wort *Getränk* ist ein Oberbegriff zum Wort *Cola*. Für diese Art von Relation gilt: Wenn ein Wort ein Oberbegriff eines anderen ist, so ist der Unterbegriff semantisch spezifischer als der Oberbegriff. Die klar unterschiedene Spezifität ist also eine notwendige Bedingung für die Hyperonym- bzw. Hyponymrelation. Das macht solche Wortpaare zu natürlichen Kandidaten, um Maße für semantische Spezifität zu testen.

Insoweit es die Textgrundlage hergibt, also in Dokumenten geordnet ist, verwende ich die *document frequency* als erste Annäherung an ein brauchbares Maß für die semantische Spezifität. Die Berechnung ist simpel und performant. Entscheidend wird die Frage sein, ob es den komplexeren Modellen gelingt, eine höhere Erfolgsrate zu erzielen. Daher verwende ich die *document frequency* als Benchmark für die anderen Modelle.

Weil das spätere Ziel ist, Worte in unterschiedlichen Korpora miteinander zu vergleichen, muss die *document frequency* noch normiert werden, wodurch das Maß etwas unabhängiger vom verwendeten Korpus wird.

**Definition.** Sei  $N$  die Gesamtzahl aller untersuchten Dokumente und  $df_i$  die Anzahl der Dokumente, in denen das Fokuswort  $w_i$  auftritt. Dann ist die **normierte document frequency**  $dfn_i$

$$dfn_i = \frac{df_i}{N} \quad (1)$$

Hat von zwei Wörtern, die wir miteinander vergleichen wollen das erste eine kleinere *dfn* als das zweite, ist das nach Caraballo und Charniak (1999) eine gute Heuristik, auch eine höhere semantische Spezifität anzunehmen.

## 2.3 Das Word Space Model

Grundlage dieser Arbeit ist das *Word Space Model* (WSM) oder auch Termvektormodell, das unter anderem sehr ausführlich in Sahlgren (2006) beschrieben wird. Das WSM erhält seine Relevanz in der Computerlinguistik hauptsächlich durch eine zentrale Überlegung:

**The distributional hypothesis:** *words with similar distributional properties have similar meanings.*

Die Formulierung hier stammt aus Sahlgren (2006, S. 21). Die Idee ist naheliegend: Dem abstrakten Konzept der Bedeutungsähnlichkeit wird durch simple räumliche Nähe repräsentiert. Die statistischen Eigenschaften eines Wortes scheinen nach der Hypothese also auf nicht näher bestimmte mit dem semantischen Inhalt eines Wortes zu korrelieren. Diese Korrelation ist jedoch nicht absolut, sondern steht in Relation zu den Eigenschaften eines anderen Wortes. Das WSM stellt also kein Modell für die absolute Bedeutung eines Wortes dar, man kann jedoch Aussagen über die Bedeutungsähnlichkeit verschiedener Worte treffen.<sup>1</sup>

Zu den statistischen Eigenschaften zählen dabei Phänomene wie die Häufigkeit eines Wortes, die Beziehungen zu anderen Worten in der unmittelbaren Umgebung des Wortes, die Beziehung zu anderen Worten im selben Dokument usw. Das WSM stellt dabei diese Eigenschaften durch Zahlenwerte von verschiedenen Features dar. Ein solches Feature wäre beispielsweise die Häufigkeit des Auftretens eines bestimmten Wortes in direkter Nachbarschaft zum Fokuswort. Die Auswahl dieser Featuremenge legt dabei in sehr relevantem Maße die Aussagen fest, die sich mit Hilfe des WSM treffen lassen. Listet man alle Features eines Fokuswortes auf, so erhält man den Featurevektor des Wortes. Dieser Vektor repräsentiert damit die statistischen Eigenschaften des Fokuswortes im Kontext des Modells, das man ausgewählt hat. Die Ähnlichkeit der Featurevektoren lässt dann Rückschlüsse auf die Bedeutungsähnlichkeit der Worte zu, so die Hypothese.

Um die Ähnlichkeit numerisch bestimmen zu können, braucht es für einen solchen Vektorraum eine Methode, die Distanz zwischen den einzelnen Featurevektoren zu bestimmen. Welche davon sinnvoll eingesetzt werden können, wird in den nächsten Abschnitten beschrieben.

## 2.4 Satzkookkurrenzen vs. Fensterkookkurrenzen

Zunächst müssen die Features, welche die Vektoren ausmachen, festgelegt werden. Ein naheliegender Kandidat sind hier diejenigen Wörter, die mit dem Fokuswort in einer bestimmten Art und Weise gemeinsam auftreten, also kookkurrieren. Über einen gesamten Korpus

---

<sup>1</sup>Je nach Bedeutungstheorie ist das mehr oder minder plausibel. Versteht man Bedeutung primär als Referenz (insbesondere extralinguistisch), so kann diese Analogie nicht viel leisten. Ist vielmehr der Gebrauch des Wortes in der Sprache gefragt, entspricht die Analogie je nach Wahl des konkreten Modells zum Teil sehr deutlich dem Begriff der Bedeutung.

legen diese Wörter den Kontext des Fokuswortes fest. Nun gibt es mehrere Möglichkeiten, diesen Kontext festzulegen. In dieser Arbeit habe ich die folgenden beiden Ansätze gewählt:

**Satzkookkurrenzen** sind diejenigen Wörter, mit denen das Fokuswort gemeinsam in einem Satz auftritt. Gezählt werden dabei für zwei Wörter vorrangig die Anzahl der Sätze, in denen die Wörter gemeinsam auftreten. Den Satzkontext des Fokuswortes bilden dann die Menge aller Wörter, die mit dem Fokuswort mindestens einmal gemeinsam in einem Satz auftreten.

**Fensterkookkurrenzen** sind diejenigen Wörter, mit denen das Fokuswort innerhalb eines Fensters von festgelegter Größe gemeinsam auftritt. In Abgrenzung zur Satzkookkurrenz habe ich hier kein symmetrisches Fenster untersucht, sondern nur die nachfolgenden Wörter betrachtet, das rechte, gerichtete Kontextfenster. Die Auswahl der Größe des Fensters ist ebenfalls relevant und führt zu signifikanten Unterschieden.

Der Featurevektor des Fokusworts besteht also aus der Kookkurrenz mit allen anderen Worten des Korpus.

**Beispiel.** Der Beispieltext

The optional plotz says to frobnicate the bizbaz first. Return a foobang.

soll analysiert werden mit *plotz* als Fokuswort<sup>2</sup>:

	optional	plotz	says	frobnicate	bizbaz	first	Return	foobang
plotz	$k_1$	$k_2$	$k_3$	$k_4$	$k_5$	$k_6$	$k_7$	$k_8$

Die Werte  $k_1$  bis  $k_8$  sind die Ausprägungen der Relation zwischen den jeweiligen Wörtern. Die Ausprägung hängt davon ab, (i) ob Satzkookkurrenz oder Fensterkookkurrenz verwendet wird und (ii) welches Maß zur Berechnung der Kookkurrenz verwendet wird. Die verschiedenen Maße, die ich verwende, werden in Abschnitt 2.6 vorgestellt.

Paradigmatischer vs. Syntagmatischer Kontext

## 2.5 Score #2: Anzahl der Kookkurenzen

Ausgehend vom vorherigen Abschnitt lässt sich eine Wort-Wort-Kookkurrenzmatrix erstellen. Diese Matrix enthält alle Featurevektoren jedes einzelnen Wortes des Korpus als Reihe. Die Matrix ist dabei zwingend quadratisch, aber nicht unbedingt symmetrisch, eben im Falle der Fensterkookkurrenzen.

Eine grundlegende These dieser Arbeit ist, dass der Kontext eines Wortes als Indiz für seine semantische Spezifität herangezogen werden kann. Nicht nur die reine Häufigkeit eines Wortes ist entscheidend, sondern auch, mit wie vielen verschiedenen Worten das Fokuswort in Kookkurrenz steht. Beispiel: Ein allgemeines Wort kommt etwas seltener vor als ein Spezielleres, der Kontext des spezielleren Wortes ist jedoch beschränkter als der des Allgemeineren, das mit vielen verschiedenen Worten kookkurriert. In so einem Fall würde die *document frequency* fälschlicherweise das allgemeinere Wort als spezieller auszeichnen.

---

<sup>2</sup>Stopwords wurden bereits entfernt.

Die Idee dieses Maßes ist es daher, einfach zu zählen, mit wie viele von Null verschiedene Einträge der Featurevektor des Fokuswortes hat, mit anderen Worten, mit wie vielen verschiedenen Worten das Fokuswort in Kookkurrenz steht.

**Definition.** Sei  $N$  die Gesamtzahl aller (unique) Worte im Korpus und  $n_i$  die Anzahl aller (unique) Worte, mit denen das Wort  $w_i$  in Kookkurrenz steht, d.h. an dessen Eintrag der Featurevektor von  $w_i$  einen von Null verschiedenen Wert aufweist. Dann ist der **Non-Zero Dimension Score**  $nzds_i$

$$nzds_i = \frac{n_i}{N} \quad (2)$$

Meine These: Ein kleiner  $nzds$ -Wert eines Wortes spricht für eine höhere semantische Spezifität, ein größerer Wert dafür, dass das Wort eher genereller ist.

## 2.6 Maße für die Kookkurrenzen

Zusätzlich zur Auswahl der Art der Kookkurrenz muss noch ein Maß zur Bestimmung der Kookkurrenz gewählt werden. In dieser Arbeit habe ich dafür vier verschiedene Maße herangezogen. Ich gebe hier die Maße für den Fall der Satzkookkurrenzen an. Für die gerichtete Fensterkookkurrenz ergeben sich leicht andere Maße, was sich auch darin zeigt, dass die resultierende Wort-Wort-Kookkurrenzmatrix nicht mehr symmetrisch zur Hauptdiagonalen ist.

### 2.6.1 Binäre Kookkurrenz

Die binäre Kookkurrenz zeigt an, ob ein Wort mit einem anderen Wort im gesamten Kontext mindestens mit einer bestimmten Frequenz in Kookkurrenz steht.

**Definition.** Seien  $K_i$  und  $K_j$  die Mengen aller Strukturen (Sätze, Fenster), in denen die Wörter  $w_i$  resp.  $w_j$  auftreten, und  $m$  die Mindestanzahl an Kookkurrenzen. Dann ist die **binäre Kookkurrenz**  $binary_{ij}$

$$binary_{ij} = \begin{cases} 1 & \text{Falls } |K_i \cap K_j| \geq m \\ 0 & \text{Falls nicht.} \end{cases}$$

Es wäre also  $b_{ij}$  gleich 1, genau dann wenn beide Wörter in mindestens  $m$  verschiedenen Sätzen gemeinsam auftreten.

### 2.6.2 Frequenz der Kookkurrenz

Die Frequenz der Kookkurrenz zählt jedes Auftreten der Kookkurrenzen.

**Definition.** Seien  $K_i$  und  $K_j$  die Mengen aller Strukturen (Sätze, Fenster), in denen die Wörter  $w_i$  resp.  $w_j$  auftreten. Dann ist die **Frequenz**  $freq_{ij}$

$$freq_{ij} = |K_i \cap K_j|$$

### 2.6.3 Dice-Koeffizient

Der Dice-Koeffizient zieht auch in Betracht, wie häufig die Worte im Korpus generell auftreten. Ein sehr häufiges Wort etwa steht mit vielen anderen Wörtern in Kookkurrenz, ohne dass dieses Auftreten besonders signifikant sein müsste. Der Dice-Koeffizient „bestraft“ solche Wörter, indem durch die Gesamtzahl der Vorkommnisse geteilt wird (Manning und Schütze, 1999, S. 299).

**Definition.** Seien  $K_i$  und  $K_j$  die Mengen aller Strukturen (Sätze, Fenster), in denen die Wörter  $w_i$  resp.  $w_j$  auftreten. Dann ist der **Dice-Koeffizient**  $dice_{ij}$

$$dice_{ij} = \frac{2|K_i \cap K_j|}{|K_i| + |K_j|}$$

### 2.6.4 Chi-Square

Pearson's Chi-Square-Test ist etwas elaborierter. Er stellt ebenfalls ein Maß für die Signifikanz der Kookkurrenz zur Verfügung, indem er das tatsächlich beobachtete Auftreten von Kookkurrenzen dem statistisch Erwartbaren gegenüberstellt. Statistisch erwartbar bedeutet dabei die rein zufällige Häufigkeit des gemeinsamen Auftretens in Kookkurrenz, wenn beide Worte unabhängig voneinander wären, d.h. kein Zusammenhang zwischen ihnen bestünde. Der Chi-Square-Wert steigt, je signifikanter die Kookkurrenz.

Zur Berechnung wird zunächst eine Kontingenztafel erstellt:

	$w_i$	$\neg w_i$
$w_j$	Anzahl Sätze mit $w_i$ und $w_j$	Anzahl Sätze ohne $w_i$ , mit $w_j$
$\neg w_j$	Anzahl Sätze mit $w_i$ , ohne $w_j$	Anzahl Sätze ohne $w_i$ und $w_j$

**Definition.** Sei  $K$  die Kontingenztafel zweier Wörter  $w_i$  und  $w_j$ ,  $O_{k,l}$  der Wert der Kontingenztafel in Zelle  $k, l$  und  $E_{k,l}$  der erwartete Wert für Zelle  $k, l$ , dann ist der Chi-Square-Wert  $chi\_sq_{i,j}$

$$chi\_sq_{ij} = \sum_{k,l} \frac{(O_{k,l} - E_{k,l})^2}{E_{k,l}}$$

Für eine detailliertere Beschreibung inklusive Berechnung des erwarteten Werts siehe Manning und Schütze (1999, S. 169ff.).

## 2.7 Distanzmaße im Vektorraum (fast unnötig)

## 2.8 Score #3: Semantische Nähe des Kontextes

Welche Informationen über semantische Spezifität lassen sich nun aus der so gewonnenen Wort-Wort-Kookkurrenzmatrix gewinnen? Ein naheliegender Ansatz wäre es, die Distanz zwischen den Featurevektoren derjenigen Wörter zu berechnen, die wir vergleichen wollen. Das Resultat wäre eine einzige Zahl, die Auskunft über die semantische Nähe beider Wörter gibt. Daraus lässt sich jedoch nicht auf die semantische Spezifität schließen. Ist die Distanz hinreichend klein, so haben die Wörter anscheinend ähnlichen semantischen Gehalt, ist die

Distanz sehr groß, unterscheiden sie sich. Welches der Wörter ist aber nun das semantisch spezifischere?

Was also scheinbar gefordert ist, ist ein Maß pro Wort für die semantische Spezifität, das sich dann mit dem Maß des anderen Wortes vergleichen lässt.

Ist zur Bestimmung der Spezifität eines Wortes nur der direkte Kontext relevant, oder könnte es sein, dass auch die statistischen Eigenschaften der Wörter des Kontextes eine Rolle spielen? Wenn ein Wort mit eher vielen verschiedenen Worten im Kontext steht, die Kontextworte sich untereinander allerdings semantisch sehr ähneln, scheint das ein Wort mit hoher semantischer Spezifität zu sein. Steht ein Wort stattdessen mit eher wenigen Worten im Kontext, diese Worte sind jedoch völlig unterschiedlich aus verschiedensten Gebieten, scheint das ein Wort mit geringer semantischer Spezifität zu sein.

Angenommen, die statistischen Eigenschaften des Kontextes sind relevant für die Spezifität, dann könnte die semantische Nähe der Kontextworte zueinander ein sehr aussagekräftiges Maß für die semantische Spezifität eines Begriffes sein.

Wie ließe sich das in ein Modell übersetzen?

Der Featurevektor des Fokuswortes beschreibt, mit welchen anderen Worten das Fokuswort in Konkurrenz steht. Für jedes dieser Wörter des Kontextes gibt es nun wiederum einen Featurevektor, der die statistischen Eigenschaften des Wortes beschreibt. Über die distributional hypothesis des Word Space Models lässt sich nun argumentieren, dass geringe intrakontextuelle Distanz im Vektorraum eine hohe semantische Nähe des Kontextes indiziert, und damit einen Hinweis auf die semantische Spezifität des Fokuswortes geben.

## **2.9 Getestete Maße**

### **2.10 Wordpaare**

### **2.11 Resultate**

## **3 Ein Modell für Anglizismen**

### **3.1 Textgrundlage**

### **3.2 Verwendete Technologien**

### **3.3 Resultate**

## **4 Konklusion**

## **5 Ausblick**

Word Sense Disambiguation!

Statistical Significance of Observed Difference



## Literatur

- Caraballo, Sharon A. und Charniak, Eugene:** Determining the Specificity of Nouns From Text. In: In Proceedings SIGDAT-99. 1999, 63–70
- Han, Jiawei, Kamber, Micheline und Pei, Jian:** Data Mining: Concepts and Techniques. Morgan Kaufmann, 2011
- Heyer, Gerhard, Quasthoff, Uwe und Wittig, Thomas:** Text Mining: Wissensrohstoff Text – Konzepte, Algorithmen, Ergebnisse. 1. Auflage. W3L-Verlag, 2008
- Jones, Karen Sparck:** A Statistical Interpretation of Term Specificity and its Application in Retrieval. In: Journal of Documentation, 28 01 1972, Nr. 1, 11–21, ISSN 0022–0418
- Manning, Christopher D. und Schütze, Hinrich:** Foundations of Statistical Natural Language Processing. MIT Press, 1999
- Sahlgren, Magnus:** The Word-space model. Dissertation, University of Stockholm (Sweden), 2006